

Assignments

- Individual Project Deadline: **Wed, 8 April 2026**
- In-Class Demo/Competition
 - Date: 9:00 -11:00, April 29, 2026, Wed
 - Location: LE1
 - All teams are invited to present in person.
- Group Project Deadline: **Apr 24, 2026 (NO slip days)**
- Problem Set Deadline: **April 30, 2026**

Lecture 10: Systems Evaluation

Chenshu Wu

Department of Computer Science

2026 Spring



香港大學

THE UNIVERSITY OF HONG KONG



Contents

- Learning Outcome: How to evaluate a system/method?
- Metrics and Charts
 - Accuracy, Precision, Recall, F1-Score
 - Confusion Matrix
 - Detection Rate and False Alarm Rate
 - ROC Curve
 - Boxplots and Violin plots
 - CDF
- Methodology



Why to evaluate?

- Ensure system requirements are met
- Understand the boundaries (including the limitations)
- Compare with benchmarks or SOTA
- Explore trade-offs


How did you evaluate your results?

- In labs and projects



Classification Metrics


- consider building a model to classify apples and oranges on a flat surface



Source: <https://kimberlyfessel.com/mathematics/data/accuracy-precision-recall/>

Accuracy

- Accuracy: all of the correctly classified observations and divide by the total number of observations
- one of the most popular classification metrics
- Imbalanced dataset; that is, what if we have 990 oranges and only 10 apples?



Confusion matrix (binary classification)

		Predicted	
		Spam	Not spam
Actual	Spam	True positive ✓	False negative ✗
	Not spam	False positive ✗	True negative ✓

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

$$\text{Precision} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}}$$




$$\text{Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

- precision measures the accuracy of positive predictions
- recall measures the ability to find all relevant positive instances

Precision and Recall

- Both precision and recall are defined in terms of just one class, oftentimes the positive—or minority—class.
- Precision-Recall Tradeoff

$$\text{F1-score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$




Confusion matrix

True material	wood	100.0%				
	plastic		99.0%	1.0%		
	ceramic		14.5%	74.8%	10.7%	
	water		0.1%	4.6%	94.3%	1.0%
	aluminum				3.8%	96.2%
		wood	plastic	ceramic	water	aluminum
		Predicted material				

Actual	push	85.0	0.0	4.0	5.0	3.0	3.0
	sweep	1.1	95.8	0.0	0.0	2.1	1.1
	clap	0.0	0.0	99.0	0.0	1.1	0.0
	slide	0.0	0.0	0.9	97.2	0.0	1.9
	circle	1.0	5.1	0.0	3.0	85.9	5.1
	zigzag	2.9	1.9	0.0	1.9	0.0	93.3
		push	sweep	clap	slide	circle	zigzag
		Predicted					

True material	A: wood desk	.83			.17	woods																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																												
---------------	--------------	-----	--	--	-----	-------	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--



When to use which?

- Precision: Use when false positives are more costly than false negatives.
- Recall: Use when false negatives are more costly than false positives.
- F1-score: Use when you want to balance precision and recall.

$$\text{Precision} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}}$$

$$\text{Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

$$\text{F1-score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$



Detection

- Detection Rate

- How many events (X) are correctly detected out of a total of N of true events? $DR = X/N$

- False Alarm Rate

- How many events are detected when there are actually no events of interests?
 - Can depend on the definition of the period/number of samples for “no events”.



- Trade-off between DR and FAR

- Applications can be more DR-sensitive or FAR-sensitive
 - ROC curve



ROC curve

- Receiver-Operating Characteristics (ROC)
- Useful to show sensitivity to threshold, or search for the best threshold




AUC-ROC

Regression Tasks


- **Example tasks:**
 - Localization
 - Heart/Breathing rate estimation
- **Calculation**
 - L1/L2 norm: $e = ||\text{estimate} - \text{ground_truth}||$
 - Consider n samples: $1/n * \text{sum}(e_i)$
 - mean squared error (MSE)
 - root mean squared error (RMSE)
- **Statistics**
 - Mean, median, percentiles
 - More informative formats?

$$\text{MSE} = \overset{\text{Mean}}{\boxed{\frac{1}{n} \sum_{i=1}^n}} \overset{\text{Error}}{\boxed{(Y_i - \hat{Y}_i)}} \overset{\text{Squared}}{\boxed{^2}}$$

Boxplots & Violin plots






showing the median, quartiles, and outliers



show the full distribution, including the median, quartiles, and the overall distribution shape

Cumulative Distribution Function (CDF)

- Show the distribution of a variable over its entire/possible range
- Give a sense of percentile performance
- Default metric for localization



Beyond Accuracy

- Computation Complexity
- Latency
- Throughput
- Memory/cpu usage
- Energy/Power consumption

- Scalability
- Security & Privacy metrics

- Usually more important for (real-time) systems
- Essential to clearly state what platforms are used for evaluation



What to evaluate

- Overall performance
 - One or two key metrics
- Ablation study
 - How different components contribute to the overall performance?
- Parameter study
 - How does the system work under all impacting factors?
- Comparison study
 - How does your method perform compared with baseline approaches?
- Cross-validation
- Field trials/Real-world evaluation

Case Study: Breathing Rate Estimation



Summary

- There are many more metrics to explore and use.
- Some are specific to certain applications/fields (eg, PESQ, STOI for speech; SSIM for images;)
- Need to decide the most appropriate metric(s) depending on your applications and the performance you care about.
- The key is that, it is important to conduct extensive evaluation in a logical and scientific manner, and report the results in a clear way.

Questions?

- Thank you!